

1)

Item	Ocorrências	Suporte
Leite	2	0.2 ✗
Café	2	0.2 ✗
Cerveja	2	0.2 ✗
Pão	5	0.5 ✓
Manteiga	5	0.5 ✓
Arroz	2	0.2 ✗
Feijão	2	0.2 ✗

2) {Pão, Manteiga} aparece em transações: T1, T2, T3, T4, T5

Ocorrências: 5

Suporte:  $5 / 10 = 0.5$

**Total de Itemsets 2: 1**

3) `from apyori import apriori`

```
# Dataset
transacoes = [
    ['Pão', 'Manteiga'], # Transação 1
    ['Pão', 'Manteiga'], # Transação 2
    ['Pão', 'Manteiga'], # Transação 3
    ['Pão'],             # Transação 4
    ['Pão'],             # Transação 5
    ['Manteiga'],        # Transação 6
    ['Manteiga'],        # Transação 7
    ['Cerveja', 'Café'], # Transação 8
    ['Arroz', 'Feijão'], # Transação 9
    ['Arroz', 'Feijão'], # Transação 10
]

# Gerar itemsets
itemsets = apriori(transacoes, min_support=0.3, min_confidence=0.8)
resultados = list(itemsets)

# Imprimir itemsets e suportes
for resultado in resultados:
    itemset = list(resultado.items)
```

```
suporte = resultado.support
print(f"Itemset: {itemset}, Suporte: {suporte:.2f}")
```

4) # Adicionar negação aos itens

```
transacoes_negadas = []
for transacao in transacoes:
    transacao_negada = []
    todos_itens = ['Pão', 'Manteiga', 'Cerveja', 'Café', 'Arroz',
'Feijão']
    for item in todos_itens:
        if item in transacao:
            transacao_negada.append(item)
        else:
            transacao_negada.append(f'NÃO_{item}')
    transacoes_negadas.append(transacao_negada)

# Aplicar Apriori
regras_negadas = apriori(transacoes_negadas, min_support=0.3,
min_confidence=0.6)
saida_negadas = list(regras_negadas)

#Regra gerada: NÃO_Pão → Manteiga
for regra in saida_negadas:
    print(regra)
```

5) from mlxtend.frequent\_patterns import apriori, association\_rules  
import pandas as pd

```
# Criar DataFrame one-hot
df = pd.DataFrame([
    [1, 1, 0, 0, 0, 0], # Pão, Manteiga
    [1, 1, 0, 0, 0, 0],
    [1, 1, 0, 0, 0, 0],
    [1, 0, 0, 0, 0, 0],
    [1, 0, 0, 0, 0, 0],
    [0, 1, 0, 0, 0, 0],
    [0, 1, 0, 0, 0, 0],
    [0, 0, 1, 1, 0, 0], # Cerveja, Café
    [0, 0, 0, 0, 1, 1], # Arroz, Feijão
    [0, 0, 0, 0, 1, 1]
], columns=['Pão', 'Manteiga', 'Cerveja', 'Café', 'Arroz', 'Feijão'])

# Gerar itemsets
```

```
itemsets = apriori(df, min_support=0.3, use_colnames=True)
print("Itemsets frequentes:\n", itemsets)

# Gerar regras
regras = association_rules(itemsets, metric='confidence',
min_threshold=0.8)
print("\nRegras:\n", regras)
```

**6)** O artigo revisa diversos métodos de visualização aplicados à análise de regras de associação, destacando como essas técnicas facilitam a identificação e interpretação de padrões em grandes volumes de dados. Entre os principais métodos apresentados estão os gráficos de rede, que representam itens e regras como nós e conexões (arestas), permitindo uma visualização intuitiva das relações entre produtos; as matrizes de heatmap, nas quais o uso de cores indica os níveis de suporte e confiança das regras; e os gráficos de dispersão (scatter plots), que posicionam as regras com base em métricas como suporte, confiança e lift, oferecendo uma visão comparativa entre elas. Essas visualizações são especialmente úteis em contextos de mercado, como na análise de cestas de compras, ao permitir a identificação de associações relevantes entre produtos, por exemplo, a recorrente compra conjunta de pão e manteiga. A utilização dessas técnicas é considerada fundamental para apoiar decisões estratégicas no setor varejista.